



Especialización en Inteligencia de negocios
Inteligencia analítica y minería de datos

ACA 3

Modelado Predictivo y Forecasting Empresarial con Python: Construcción y Documentación de
un Proyecto Analítico End-to-End

Presentado por:

Jorge Andrés Medina Rincon

Michael Daniel Peñuela Bello

Wendy Yasmin Tautiva Melo

Bogotá, Cundinamarca 20 de septiembre

TABLA DE CONTENIDO

INTRODUCCIÓN	3
DESARROLLO	4
PARTE 1: Metodología y Preprocesamiento en Python.....	4
1.1. Definición del problema de negocio.....	4
1.2. Descripción del dataset	4
1.3. Limpieza de datos y manejo de anomalías	5
1.4. Análisis de valores atípicos (outliers).....	7
1.5. Feature Engineering e Identificación de Clientes (Modelo RFM)	7
1.5.1. Definición de la Variable Objetivo (Target) y Prevención de Data Leakage	8
1.6. División de datos: separación en entrenamiento, validación y prueba.....	9
PARTE 2: Modelos de clasificación	10
2.1. Entrenamiento y Comparación en el Conjunto de Validación	10
2.1.1. Evaluación Técnica en el Conjunto de Test.....	11
PARTE 3: Modelos de Series de Tiempo	12
3.1. Construcción del Dataset Temporal	12
3.2. Exploración Temporal y Descomposición Estacional	13
3.2.1. Descomposición de la Serie Temporal	14
3.2.2. Hallazgos importantes	14
3.3. Modelado Predictivo con ARIMA	15
3.3.1. Construcción del modelo ARIMA.....	15
3.3.2. Evaluación de pronósticos.....	16
3.4. Análisis de Resultados y Diagnóstico de Residuos	16
PARTE 4: Interpretación del Negocio.....	17
4.1. ¿Qué decisiones podría tomar una empresa del sector elegido?	17
4.2. ¿Cómo impactan los modelos en la operación o estrategia?	18
4.3. ¿Qué riesgos y limitaciones deben considerarse?	18
4.4. ¿Qué mejoras futuras se recomiendan?	19
CONCLUSIONES	20
TRABAJOS CITADOS	22

INTRODUCCIÓN

En el contexto económico actual, caracterizado por la digitalización acelerada y la alta competitividad en los mercados globales, las organizaciones del sector minorista y de comercio electrónico (E-Commerce) se enfrentan a volúmenes masivos de datos generados segundo a segundo a través de sus canales transaccionales. De acuerdo con Provost y Fawcett (2013), la ventaja competitiva contemporánea no radica únicamente en la capacidad de almacenar grandes volúmenes de datos, sino en la aptitud sistemática de transformar dichos registros en conocimiento accionable y decisiones basadas en datos: Inteligencia de los datos (Machine Learning).

Dentro de los desafíos operacionales y estratégicos más críticos para una compañía de comercio minorista destacan dos vertientes fundamentales: la fidelización de su base de clientes y la optimización de su cadena de suministro. Por un lado, la deserción de clientes (Customer Churn) representa una de las mayores fuentes de erosión de rentabilidad, dado que el coste de adquisición de un nuevo cliente suele superar ampliamente el coste de retención de un cliente existente (Han et al., 2012). Por otro lado, la volatilidad de la demanda y la incapacidad de proyectar con precisión las ventas futuras conllevan riesgos en el abastecimiento de los productos.

Frente a esta problemática, este proyecto desarrolla y documenta una solución analítica end to end, implementada en el lenguaje de programación Python. El estudio adopta un enfoque que articula dos de los modelos analíticos más relevantes de la inteligencia de negocios: el modelado de clasificación supervisada y el modelado de series de tiempo (Forecasting), aplicados de acuerdo con un dataset de pruebas, pero que en su defecto se puede llevar a cabo en un caso de una empresa real de comercio minorista o retail, o e-commerce respectivamente.

DERSARROLLO

PARTE 1: Metodología y Preprocesamiento en Python

1.1. Definición del problema de negocio

Para el desarrollo del presente proyecto se emplea un dataset de carácter académico y de pruebas. Con el propósito de contextualizar el análisis y facilitar la comprensión de los resultados se plantea un escenario de empresarial hipotético denominado “Compañía X”.

La compañía X se encuentra ubicada en el sector del comercio mayorista y minorista de artículos de regalo y decoración, bajo un modelo de negocio de comercio electrónico. La empresa desarrolla sus actividades comerciales desde el Reino Unido y comercializa sus productos a nivel internacional a través de canales digitales. En su operación, la gerencia enfrenta las siguientes problemáticas:

1. **Retención de Clientes (*Customer Churn*):** Para la compañía es importante llevar a cabo un análisis sobre la retención de sus clientes, con el fin de identificar a tiempo que clientes están en riesgo de deserción y en que momentos es necesario llevar a cabo campañas y metodologías de marketing para fidelizar clientes.
2. **Planificación de Inventario y Demanda (*Demand Forecasting*):** La compañía necesita llevar a cabo procesos de aprovisionamiento de inventario: sin contar con exceso de inventario inmovilizado durante meses o desabastecimiento severo en picos de ventas.

Para resolver ambas problemáticas, se formula un pipeline analítico que extrae patrones de dos vertientes: el perfil comportamental de cada cliente (clasificación) y la dinámica de las ventas consolidadas en el tiempo (análisis temporal).

1.2. Descripción del dataset

- **Fuente:** Repositorio de Kaggle (*Online Retail II Dataset*), documentado originalmente por Chen et al. (2012). Recuperado de <https://www.kaggle.com/datasets/lakshmi25npathi/online-retail-dataset>

- **Tamaño Original:** 1,067,371 registros transaccionales integrados verticalmente a partir de dos archivos anuales continuos (períodos 2023–24 con 525,461 filas y 2024–25 con 541,910 filas).
- **Estructura y Tipos de Datos Iniciales:**

Tabla

1

Descripción de la estructura del dataset inicial

Variable	Tipado inicial	Descripción en el negocio
Invoice	string	Código de 6 dígitos único por factura. Si inicia con “C”, indica cancelación.
StockCode	string	Identificador único del producto comercializado.
Description	text	Nombre o descripción corta del artículo.
Quantity	int	Unidades compradas por cada línea de producto.
InvoiceDate	text	Fecha y hora exacta de registro de la transacción.
Price	float	Precio unitario por producto en libras esterlinas (£).
Customer ID	float	Código de 5 dígitos asignado al cliente.
Country	string	País de residencia del cliente comprador.

Nota. Adaptado de la estructura inicial del dataset empleada en el proyecto. Recuperado de <https://colab.research.google.com/drive/1VFj2FilCWUtxYKndauH1ALuAm-SonoGv?authuser=3#scrollTo=WwdZspDuRg8E>

```
... Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).
/dataset cargado 2023-24: 525,461 filas y 8 columnas.
/dataset cargado 2024-25: 541,910 filas y 8 columnas.
```

	Invoice	StockCode	Description	Quantity	InvoiceDate	Price	Customer ID	Country
0	489434	85048	15CM CHRISTMAS GLASS BALL 20 LIGHTS	12	01/12/2023 07:45	6.95	13085.00	United Kingdom
1	489434	79323P	PINK CHERRY LIGHTS	12	01/12/2023 07:45	6.75	13085.00	United Kingdom
2	489434	79323W	WHITE CHERRY LIGHTS	12	01/12/2023 07:45	6.75	13085.00	United Kingdom
3	489434	22041	RECORD FRAME 7" SINGLE SIZE	48	01/12/2023 07:45	2.10	13085.00	United Kingdom
4	489434	21232	STRAWBERRY CERAMIC TRINKET BOX	24	01/12/2023 07:45	1.25	13085.00	United Kingdom

Figura 1. Estructura inicial del dataset. Elaboración propia a partir de resultado obtenidos mediante Python

1.3. Limpieza de datos y manejo de anomalías

Al inspeccionar el dataset inicial con funciones exploratorias `.info()` y `.describe()`, se identificaron diversas distorsiones entre las cuales se encontraron las siguientes:

- Existencia de cantidades negativas extremas (con un valor mínimo de -80,995 unidades) y precios negativos (mínimo de -53,594 £) las cuales se deduce son correcciones contables y/o devoluciones realizadas en los periodos comprendidos.
- Más de 235.000 transacciones sin identificador de cliente (Customer ID nulo), representativas de compras anónimas o usuarios no logueados.
- Facturas con prefijo 'C' correspondientes a órdenes canceladas, un total de 18,390 registros.

Para la limpieza de este dataset se implementó el siguiente código, y el proceso de limpieza arrojó los siguientes resultados finales:

```
#limpieza de datos

n_inicial = len(df)
print(f"Total registros iniciales: {n_inicial:,}")

df.columns = df.columns.str.strip()
df.rename(columns={'Invoice': 'InvoiceNo', 'Customer ID': 'CustomerID', 'Price': 'UnitPrice'}, inplace=True)

duplicados = df.duplicated().sum()
print(f"Duplicados encontrados y eliminados: {duplicados:,}")
df.drop_duplicates(inplace=True)

#eliminacion de clientes nulos debido a que para el analisis es necesario entender quien es el cliente
nulos_clientes = df['CustomerID'].isnull().sum()
print(f"Registros sin CustomerID eliminados: {nulos_clientes:,}")
df.dropna(subset=['CustomerID'], inplace=True)

#para el analisis posterior no es necesario facturas canceladas
df['InvoiceNo'] = df['InvoiceNo'].astype(str)
cancelaciones = df['InvoiceNo'].str.upper().str.startswith('C').sum()
print(f"Facturas de cancelación (inician con 'C') eliminadas: {cancelaciones:,}")
df = df[~df['InvoiceNo'].str.upper().str.startswith('C')]

#depuracion de outliers
anomalias_qty_price = ((df['Quantity'] <= 0) | (df['UnitPrice'] <= 0)).sum()
print(f"Registros con Quantity o UnitPrice <= 0 eliminados: {anomalias_qty_price:,}")
df = df[(df['Quantity'] > 0) & (df['UnitPrice'] > 0)]

df['CustomerID'] = df['CustomerID'].astype(int).astype(str) # Identificador en string
df['InvoiceDate'] = pd.to_datetime(df['InvoiceDate'], dayfirst=True) # Formato fecha

n_final = len(df)
eliminados = n_inicial - n_final

print("\n" + f"Registros limpios finales: {n_final:,}")
print(f"Total registros eliminados: {eliminados:,} ({(eliminados/n_inicial)*100:.2f}%)")
```

```
Total registros iniciales: 1,067,371
Duplicados encontrados y eliminados: 34,335
Registros sin CustomerID eliminados: 235,151
Facturas de cancelación (inician con 'C') eliminadas: 18,390
Registros con Quantity o UnitPrice <= 0 eliminados: 70

Registros limpios finales: 779,425
Total registros eliminados: 287,946 (26.98%)
```

Figura 2. Código de implementación de limpieza. Elaboración propia a partir de resultados obtenidos mediante Python

1.4. Análisis de valores atípicos (outliers)

Para el análisis de valores extremos se implemento un diagrama de cajas y bigotes en escala logarítmica sobre las variables de Quantity, UnitPrice y TotalAmount:

- La distribución intercuartílica reveló que el 75% de las compras no superan las 12 unidades por producto, con un precio unitario inferior a 3.75 £ y un importe por línea mediano de 12.48 £.
- No obstante, se confirmaron transacciones mayoristas legítimas con órdenes de hasta 80,000 unidades y montos de hasta 168,469.60 £. Estas transacciones se conservaron intactas, dado que corresponden a clientes mayoristas (*wholesalers*) que representan el núcleo de ingresos del negocio y no a errores de digitación.




Figura 3. Gráfico BoxPlot para análisis de datos atípicos. Elaboración propia a partir de resultado obtenidos mediante Python

1.5. Feature Engineering e Identificación de Clientes (Modelo RFM)

Dado que el dataset limpio es a nivel de transacción individual, para el modelo de clasificación se requirió una agregación a nivel de cliente para reconstruir su comportamiento histórico tomando como referenci el marco RFM (*Recency, Frequency, Monetary*):

1. **Frequency:** Conteo de facturas únicas registradas por el cliente `InvoiceNo.nunique()`
2. **Monetary:** Gasto total acumulado por cliente en la moneda del país `TotalAmount.sum()`
3. **TotalQuantity:** Suma total de unidades físicas adquiridas.

4. **AvgTicket:** Ticket promedio de compra generado (**Monetary / Frequency**).
5. **Is_UK:** Variable de tipo binario, codificada con valor 1 si el cliente reside en el Reino Unido y 0 para clientes internacionales.

1.5.1. Definición de la Variable Objetivo (Target) y Prevención de Data Leakage

La variable objetivo (Churn) se definió como un indicador binario de inactividad del cliente. Se consideró que un cliente entraba en estado de deserción cuando habían transcurrido más de 90 días desde su última compra. Formalmente:

$$Churn = \begin{cases} 1, & \text{si los días desde la última compra} > 90 \\ 0, & \text{en caso contrario (cliente inactivo)} \end{cases}$$

Durante la construcción del modelo se tuvo especial cuidado en evitar problemas de fuga de información. La variable recency, que mide el número de días transcurridos desde la última compra, no fue incluida dentro del conjunto de variables predictoras.

La razón es que esta métrica se encuentra directamente relacionada con la definición del objetivo. Si recency hubiera sido utilizada como predictor, el modelo podría aprender una regla trivial del tipo:

$$Recency > 90 = Churn = 1$$

En este escenario, el algoritmo alcanzaría niveles de precisión artificialmente altos sin aportar capacidad real de predicción, ya que estaría utilizando información que prácticamente define la variable objetivo. Por esta razón, Recency fue excluida deliberadamente del conjunto de entrenamiento, obligando a los modelos a identificar el riesgo de abandono a partir de otros aspectos del comportamiento del cliente, como sus patrones de compra, la frecuencia de transacciones y el valor monetario generado históricamente.

La base consolidada estuvo compuesta por 5.878 clientes, con una distribución equilibrada de la variable objetivo: 50,85 % correspondieron a clientes clasificados como Churn (1) y 49,15 % a clientes Activos (0).

Fecha de analisis: 10/12/2025
Distinct de clientes analizados: 5,878

Distribución de la variable objetivo (churn)

Churn

1 50.85
0 49.15

Name: proportion, dtype: float64

	CustomerID	Recency	Frequency	Monetary	TotalQuantity	Country	AvgTicket	Is_UK	Churn
0	12346	326	12	77556.46	74285	United Kingdom	6463.04	1	1
1	12347	2	8	4921.53	2967	Iceland	615.19	0	0
2	12348	75	5	2019.40	2714	Finland	403.88	0	0
3	12349	19	4	4428.69	1624	Italy	1107.17	0	0
4	12350	310	1	334.40	197	Norway	334.40	0	1

Figura 4. Distribución de la variable Churn obtenida. Elaboración propia a partir de resultado obtenidos mediante Python

1.6. División de datos: separación en entrenamiento, validación y prueba.

Con el propósito de evaluar el desempeño de los modelos de manera objetiva y minimizar el riesgo de sobreajuste, la base de datos se dividió utilizando una estrategia de división de datos estratificada (*stratify* = *y*). Este enfoque garantiza que la proporción de clientes activos y clientes en churn se mantenga prácticamente igual en cada subconjunto generado.

```
#division del dataset (train, val, test)
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

#variables predictoras (X) y variable objetivo (y)
features = ['Frequency', 'Monetary', 'TotalQuantity', 'AvgTicket', 'Is_UK']
X = df_clientes[features]
y = df_clientes['Churn']

#partición: 70% Train, 30% Temporal (Val + Test)
X_train, X_temp, y_train, y_temp = train_test_split(
    X, y, test_size=0.30, random_state=42, stratify=y)

#partición: dividimos el 30% en dos partes iguales (15% Val y 15% Test)
X_val, X_test, y_val, y_test = train_test_split(
    X_temp, y_temp, test_size=0.50, random_state=42, stratify=y_temp
)

#escalamiento de variables con StandardScaler
scaler = StandardScaler()
# evitacion de contaminacion train
X_train_scaled = scaler.fit_transform(X_train)
X_val_scaled = scaler.transform(X_val)
X_test_scaled = scaler.transform(X_test)

#dataset convertido
X_train_scaled = pd.DataFrame(X_train_scaled, columns=features)
X_val_scaled = pd.DataFrame(X_val_scaled, columns=features)
X_test_scaled = pd.DataFrame(X_test_scaled, columns=features)

print(f"Conjunto de Entrenamiento (Train 70%): {X_train.shape[0]} registros")
print(f"Conjunto de Validación (Val 15%): {X_val.shape[0]} registros")
print(f"Conjunto de Prueba (Test 15%): {X_test.shape[0]} registros")

X_train_scaled.head()
```

Conjunto de Entrenamiento (Train 70%):	4114 registros
Conjunto de Validación (Val 15%):	882 registros
Conjunto de Prueba (Test 15%):	882 registros

	Frequency	Monetary	TotalQuantity	AvgTicket	Is_UK
0	-0.39	-0.19	-0.22	-0.11	0.32
1	1.44	0.32	0.53	-0.07	0.32
2	-0.39	-0.19	-0.24	-0.08	0.32
3	0.22	-0.12	-0.14	-0.18	0.32

Figura 5. Código de implementación de división de datos. Elaboración propia a partir de resultados obtenidos mediante Python

La distribución final de los datos fue la siguiente:

- **Conjunto de entrenamiento (70%): 4.114 clientes**, utilizado para entrenar los modelos y ajustar sus parámetros internos.
- **Conjunto de validación (15%): 882 clientes**, empleado durante la fase de ajuste de parámetros y selección del modelo con mejor desempeño.
- **Conjunto de prueba (15%): 882 clientes**, reservado exclusivamente para la evaluación final sobre datos no utilizados durante el entrenamiento ni la validación.

Esta separación permitió obtener una estimación más confiable de la capacidad de generalización de los modelos ante nuevos clientes.

PARTE 2: Modelos de clasificación

Con el fin de identificar el modelo con mejor capacidad para predecir la deserción de clientes, se evaluaron dos algoritmos de clasificación:

- 1. Regresión logística:** La Regresión Logística fue utilizada como modelo base de comparación (*benchmark*), ya que es uno de los métodos más utilizados en problemas de clasificación binaria. Este algoritmo estima la probabilidad de que un cliente pertenezca a la clase *Churn* a partir de las variables disponibles. Entre sus principales ventajas se encuentran su facilidad de interpretación y su bajo costo computacional, lo que permite comprender el efecto que tiene cada variable sobre la probabilidad de deserción. Sin embargo, su principal limitación es que asume relaciones lineales entre las variables predictoras y la probabilidad del evento, por lo que puede tener dificultades para capturar patrones más complejos presentes en los datos.
- 2. Tabla de hechos:** Random Forest es un algoritmo basado en la combinación de múltiples árboles de decisión. Cada árbol genera una predicción y el resultado final se obtiene a partir del consenso de todos ellos. Se seleccionó este modelo debido a su capacidad para identificar relaciones no lineales y patrones complejos entre las variables, características que suelen estar presentes en el comportamiento de compra de los clientes. Además, es un modelo robusto frente a valores atípicos y proporciona métricas de importancia de variables, lo que facilita identificar cuáles son los factores que más influyen en el riesgo de abandono.

2.1. Entrenamiento y Comparación en el Conjunto de Validación

Ambos modelos fueron entrenados sobre las 4,114 observaciones del conjunto de entrenamiento y comparados imparcialmente sobre las 882 observaciones del conjunto de validación. Obteniendo los siguientes resultados:

```

#entrenamiento y comparacion de modelos de clasificacion
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score, roc_auc_score

modelo_lr = LogisticRegression(random_state=42)
modelo_rf = RandomForestClassifier(n_estimators=100, max_depth=6, random_state=42)

#entrenamiento con el modelo training
modelo_lr.fit(X_train_scaled, y_train)
modelo_rf.fit(X_train, y_train) # Random Forest no requiere escalamiento estricto, usa X_train directamente

def calcular_metricas(modelo, X, y, escalado=False):
    y_pred = modelo.predict(X)
    y_prob = modelo.predict_proba(X)[:, 1]
    return {
        'Accuracy': accuracy_score(y, y_pred),
        'Precision': precision_score(y, y_pred),
        'Recall': recall_score(y, y_pred),
        'F1-Score': f1_score(y, y_pred),
        'AUC-ROC': roc_auc_score(y, y_prob)
    }

metricas_lr_val = calcular_metricas(modelo_lr, X_val_scaled, y_val)
metricas_rf_val = calcular_metricas(modelo_rf, X_val, y_val)

df_comparativa = pd.DataFrame([metricas_lr_val, metricas_rf_val], index=['Logistic Regression', 'Random Forest'])
print("comparativa tecnica")
print(df_comparativa.round(4))

```

comparativa tecnica	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Logistic Regression	0.69	0.66	0.78	0.72	0.75
Random Forest	0.69	0.69	0.71	0.70	0.76

Figura 6. Código de implementación del entrenamiento del modelo de clasificación. Elaboración propia a partir de resultado obtenidos mediante Python

De acuerdo con los resultados obtenidos, el modelo seleccionado fue el Random Forest, por estas tres razones:

- Mayor Capacidad Discriminante Global: Registró un AUC-ROC superior al 76%, lo que demuestra una mejor separación probabilística entre clientes activos y desertores (Fawcett, 2006).
- Equilibrio Precisión-Sensibilidad: Presentó una precisión notablemente superior, 69% frente al 66%, evitando saturar al equipo de marketing con falsas alertas.
- Capacidad: Permite extraer el orden jerárquico de las variables del negocio que impulsan la deserción.

2.1.1. Evaluación Técnica en el Conjunto de Test

El modelo Random Forest fue puesto a prueba sobre los 882 clientes del conjunto de prueba (Test), datos que permanecieron completamente aislados durante todo el entrenamiento y ajuste. Obteniendo las siguientes métricas de desempeño, mediante Python:




Figura 7. Reporte tecnico detallado del modelo en Prueba. Elaboración propia a partir de resultado obtenidos mediante Python

- Exactitud Global (*Accuracy*): 70.75% (0.7075). El modelo clasifica correctamente a más de 7 de cada 10 clientes.
- Precisión (*Precision - Churn*): 69.45% (0.6945). De todos los clientes que el modelo predijo que abandonarían, casi el 70% efectivamente lo hizo.
- Sensibilidad (*Recall - Churn*): 75.95% (0.7595). De la totalidad de clientes que realmente desertaron, el modelo logró identificar anticipadamente al 76%.
- F1-Score (*Churn*): 72.55% (0.7255). Media armónica que confirma la solidez y estabilidad del clasificador.
- **Área Bajo la Curva ROC (*AUC-ROC*): 0.776 (77.6%).**

PARTE 3: Modelos de Series de Tiempo

3.1. Construcción del Dataset Temporal

Para realizar el análisis de series temporales, fue necesario transformar los registros individuales de venta en una secuencia cronológica agregada que permitiera estudiar la evolución de los ingresos a lo largo del tiempo.

A partir de los 779.425 registros transaccionales depurados, se realizaron las siguientes etapas:

1. Se seleccionaron las variables InvoiceDate (fecha de la transacción) y TotalAmount (valor de la venta).
2. La columna InvoiceDate se estableció como índice temporal del conjunto de datos.

3. Los valores se agregaron mediante una frecuencia semanal, sumando el total de ingresos generados en cada periodo.

```
Total de semanas: 106
Rango de fechas: 03/12/2023 a 07/12/2025

test de dickey fuller aumentado (ADF)
Estadístico ADF: -3.8025
p-valor: 0.0029
conclusion: La serie es Estacionaria (p <= 0.05).
```

Se optó por trabajar con una agregación semanal en lugar de una diaria debido a que los datos diarios presentaban una alta variabilidad, influenciada por factores como fines de semana, festivos y días sin actividad comercial. La consolidación por semanas permitió obtener una serie más estable y representativa del comportamiento general del negocio, facilitando la identificación de tendencias y patrones de demanda a lo largo del tiempo.

Como resultado, se obtuvo una serie temporal compuesta por 106 semanas consecutivas, comprendidas entre el 3 de diciembre de 2023 y el 7 de diciembre de 2025, lo que equivale aproximadamente a dos años de operación comercial.

3.2. Exploración Temporal y Descomposición Estacional

Antes de construir modelos de series temporales, se evaluó si la serie de ventas semanales cumplía con el supuesto de estacionariedad, es decir, que sus propiedades estadísticas se mantienen relativamente estables a lo largo del tiempo.

Para ello, se aplicó la prueba de Dickey-Fuller Aumentado (ADF), cuyas hipótesis son:

- H_0 : La serie no es estacionaria.
- H_1 : La serie es estacionaria.

Resultados obtenidos:

- Estadístico ADF: -3.8025
- p-valor: 0.0029

Dado que el p-valor es inferior al nivel de significancia de 0.05, se rechaza la hipótesis nula. Por lo tanto, existe evidencia estadística suficiente para considerar que la serie de ventas semanales es estacionaria y puede utilizarse para el análisis y modelado de series temporales.

3.2.1. Descomposición de la Serie Temporal

Con el objetivo de comprender mejor el comportamiento de las ventas a lo largo del tiempo, se realizó una descomposición aditiva de la serie temporal:

$$Y_t = T_t + S_t + R_t$$

donde:

- Y_t : ventas observadas.
- T_t : componente de tendencia.
- S_t : componente estacional.
- R_t : componente residual o aleatoria.

Se utilizó una periodicidad de **52 semanas**, equivalente a un ciclo anual completo.




Figura 8. Descomposición Temporal de Ventas Semanales (Observada, Tendencia, Estacionalidad, Residuos). Elaboración propia a partir de resultado obtenidos mediante Python

3.2.2. Hallazgos importantes

- **Serie observada:** La serie de ventas presenta fluctuaciones recurrentes a lo largo del tiempo, destacándose incrementos importantes en determinados periodos del año.

- **Tendencia:** La tendencia general muestra un crecimiento durante gran parte de 2024, seguido de una desaceleración a comienzos de 2025 y posteriormente una recuperación gradual hacia finales del periodo analizado.
- **Estacionalidad:** La componente estacional evidencia un patrón anual claramente definido. Los mayores incrementos de ventas se concentran entre las semanas 40 y 50 de cada año, correspondientes aproximadamente a los meses de octubre, noviembre y diciembre. Este comportamiento coincide con eventos comerciales de alta demanda como Black Friday, Navidad o Fin de Año, periodos en los que las ventas superan significativamente el promedio habitual.
- **Residuos:** El componente residual oscila alrededor de cero y no presenta patrones evidentes, lo que indica que la tendencia y la estacionalidad explican una parte importante de la variabilidad observada en la serie.

3.3. Modelado Predictivo con ARIMA

A diferencia de los modelos de clasificación, donde las observaciones pueden dividirse aleatoriamente, en las series temporales es fundamental conservar el orden cronológico de los datos. De esta forma, el modelo aprende únicamente de información pasada y se evalúa sobre datos futuros, replicando un escenario real de pronóstico.

La partición utilizada fue la siguiente:

- Conjunto de entrenamiento: primeras 94 semanas de la serie (diciembre de 2023 a septiembre de 2025), utilizadas para ajustar el modelo.
- Conjunto de prueba: últimas 12 semanas (octubre a diciembre de 2025), reservadas para evaluar la capacidad predictiva del modelo.

El horizonte de prueba corresponde aproximadamente a un trimestre completo de operación comercial.

3.3.1. Construcción del modelo ARIMA

Para realizar el pronóstico de ventas se empleó un modelo ARIMA(1,1,1), implementado mediante la librería statsmodels.

Los parámetros del modelo indican que:

- $p = 1$: considera la influencia de la observación inmediatamente anterior.
- $d = 1$: aplica una diferenciación de primer orden para estabilizar la serie.
- $q = 1$: incorpora el efecto de errores pasados en la predicción.

El modelo fue entrenado con las primeras 94 semanas de información y posteriormente utilizado para generar pronósticos sobre las 12 semanas del conjunto de prueba.

3.3.2. Evaluación de pronósticos

Las predicciones obtenidas se compararon con los valores reales observados durante las 12 semanas del conjunto de prueba. Para medir la precisión del modelo se utilizaron tres métricas ampliamente empleadas en series temporales.

- **Error Absoluto Medio (MAE):** El MAE indica que, en promedio, las predicciones presentaron una diferencia cercana a £97.475 respecto a las ventas reales de cada semana.
- **Raíz del Error Cuadrático Medio (RMSE):** El RMSE fue de £102.334, un valor cercano al MAE. Esto sugiere que los errores se distribuyen de manera relativamente uniforme y que no existen desviaciones extremadamente grandes que afecten significativamente el desempeño del modelo.
- **Error Porcentual Absoluto Medio (MAPE):** El MAPE alcanzó un valor de 37,07%, lo que significa que las predicciones presentaron una desviación promedio cercana al 37% respecto a los valores reales.

Este resultado puede explicarse por el hecho de que el período de prueba coincide con la temporada de mayor actividad comercial del año, caracterizada por eventos promocionales y compras navideñas que generan incrementos importantes en las ventas.

3.4. Análisis de Resultados y Diagnóstico de Residuos

Semanas de Entrenamiento (Train): 94
Semanas de Prueba (Test Horizon): 12
evaluación técnica del pronóstico (test)
MAE (Error Absoluto Medio): £97,475.48
RMSE (Raíz del Error Cuadrático Medio): £102,334.47
MAPE (Error Porcentual Absoluto Medio): 37.07%




Figura 9. Modelo de series de tiempo (arima/sarima). Elaboración propia a partir de resultado obtenidos mediante Python

Durante las 12 semanas evaluadas se observó un crecimiento significativo de las ventas, impulsado principalmente por la temporada de fin de año. El modelo ARIMA logró capturar la tendencia general de la serie; sin embargo, tendió a subestimar la magnitud del incremento observado en las semanas de mayor demanda.

A pesar de ello, las ventas reales permanecieron dentro de los intervalos de confianza generados por el modelo, lo que indica que la incertidumbre asociada al pronóstico fue estimada de manera razonable.

Como parte de la validación del modelo, se analizaron los residuos, definidos como la diferencia entre los valores reales y las predicciones. El histograma de residuos muestra una distribución aproximadamente centrada en cero, sin evidencias claras de sesgos sistemáticos. Esto sugiere que el modelo no tiende a sobreestimar ni subestimar las ventas de forma constante. En conjunto, los resultados indican que el modelo ARIMA proporciona una aproximación razonable al comportamiento general de la serie, aunque presenta dificultades para anticipar incrementos abruptos de demanda asociados a eventos estacionales de alta intensidad, como las campañas comerciales de fin de año.

PARTE 4: Interpretación del Negocio.

4.1. ¿Qué decisiones podría tomar una empresa del sector elegido?

Los resultados obtenidos permiten generar información útil para apoyar la toma de decisiones en distintas áreas del negocio, especialmente en marketing, fidelización y planificación comercial.

- **Estrategias de retención de clientes**

El modelo de clasificación logró identificar una proporción importante de los clientes con riesgo de abandono. Esto permite que el área de marketing implemente campañas de retención más focalizadas, dirigiendo promociones, descuentos o comunicaciones personalizadas únicamente a los clientes con mayor probabilidad de deserción. De esta manera, los recursos pueden utilizarse de forma más eficiente, evitando campañas masivas sobre toda la base de clientes y concentrando los esfuerzos en los segmentos con mayor riesgo.

- **Fortalecimiento de programas de fidelización**

El análisis de importancia de variables indicó que la frecuencia de compra es uno de los factores más relevantes para explicar el abandono de clientes. Con base en este hallazgo, la empresa podría diseñar programas de fidelización orientados a aumentar la recurrencia de compra, por ejemplo

mediante beneficios por compras repetidas, acumulación de puntos o promociones exclusivas para clientes frecuentes.

- **Planificación de inventarios y abastecimiento**

Los resultados del modelo de pronóstico proporcionan una referencia sobre el comportamiento esperado de las ventas durante los próximos períodos. Esta información puede apoyar la planificación de compras, la gestión de inventarios y la coordinación logística, reduciendo riesgos asociados tanto a faltantes de productos como a sobreabastecimiento.

4.2. ¿Cómo impactan los modelos en la operación o estrategia?

- **Impacto operativo**

La implementación de modelos predictivos puede contribuir a mejorar la eficiencia operativa de la organización. Por un lado, la identificación temprana de clientes en riesgo permite desarrollar acciones de retención antes de que ocurra la pérdida del cliente. Por otro, los pronósticos de ventas facilitan una mejor planificación de inventarios y recursos logísticos, reduciendo costos asociados a exceso o escasez de stock.

- **Impacto estratégico**

Desde una perspectiva estratégica, el uso de analítica predictiva permite adoptar una gestión más orientada a los datos. En lugar de reaccionar cuando un cliente deja de comprar o cuando la demanda ya ha cambiado, la empresa puede anticiparse a estos comportamientos y tomar decisiones preventivas basadas en evidencia. Esto favorece una cultura de toma de decisiones más proactiva y alineada con los objetivos comerciales de largo plazo.

4.3. ¿Qué riesgos y limitaciones deben considerarse?

Aunque los resultados obtenidos son satisfactorios, es importante considerar algunas limitaciones del análisis.

- **Exclusión de compras sin identificación de cliente**

Para construir el modelo de churn fue necesario trabajar únicamente con clientes identificados. Como consecuencia, se excluyeron las transacciones que no contaban con un identificador de cliente, por lo que las estrategias de retención derivadas del modelo solo aplican a la base de clientes registrados.

- **Limitaciones del modelo de pronóstico**

Si bien el modelo ARIMA logró capturar la tendencia general de las ventas, presentó dificultades para anticipar incrementos extraordinarios de demanda asociados a eventos comerciales específicos, como campañas promocionales o temporadas de alta actividad.

- **Cambios en el comportamiento de los clientes**

Los modelos fueron entrenados utilizando información histórica y asumen que los patrones observados se mantendrán relativamente estables en el tiempo. Sin embargo, factores externos como cambios económicos, variaciones en el mercado o modificaciones en la estrategia comercial pueden afectar su desempeño y requerir actualizaciones periódicas.

4.4. ¿Qué mejoras futuras se recomiendan?

Como líneas de mejora para futuras investigaciones o implementaciones empresariales, se proponen las siguientes iniciativas:

- **Incorporación de variables externas en los pronósticos**

Se recomienda explorar modelos que incorporen variables externas tales como festivos, campañas promocionales, inversiones en marketing o eventos comerciales especiales. Esto podría mejorar la precisión de los pronósticos durante temporadas de alta demanda.

- **Análisis del valor de vida del cliente (CLV)**

Una extensión interesante sería combinar la probabilidad de abandono con métricas de valor del cliente (*Customer Lifetime Value*). Esto permitiría priorizar las acciones de retención sobre aquellos clientes que generan un mayor aporte económico para la empresa.

- **Implementación en entornos productivos**

Finalmente, se recomienda integrar los modelos dentro de los procesos operativos de la organización mediante flujos automatizados de actualización y monitoreo. Esto permitiría generar alertas periódicas sobre clientes en riesgo y disponer de pronósticos actualizados para apoyar la toma de decisiones comerciales.

CONCLUSIONES

- El desarrollo del modelo de clasificación permitió identificar patrones de comportamiento asociados a la deserción de clientes, demostrando que variables como la frecuencia de compra y el gasto acumulado son determinantes para estimar el riesgo de abandono. El modelo Random Forest obtuvo el mejor desempeño, alcanzando una exactitud del 70,75% y una sensibilidad del 75,95%, lo que evidencia su utilidad para apoyar estrategias de retención y fidelización de clientes.
- El análisis de series temporales permitió comprender la evolución de las ventas y detectar patrones estacionales relevantes para el negocio. La descomposición de la serie evidenció incrementos significativos de demanda durante los últimos meses de cada año, asociados a eventos comerciales y a la temporada navideña. Aunque el modelo ARIMA(1,1,1) presentó limitaciones para anticipar picos excepcionales de ventas, logró capturar adecuadamente la tendencia general y proporcionar una referencia útil para la planificación de inventarios y abastecimiento.
- Los resultados obtenidos demuestran el valor de la analítica predictiva como herramienta de apoyo para la toma de decisiones en organizaciones del sector retail. La combinación de modelos de clasificación y forecasting permitió abordar simultáneamente dos problemáticas estratégicas: la retención de clientes y la planificación de la demanda. De esta manera, la organización puede pasar de una gestión reactiva a una gestión basada en datos, anticipándose a riesgos comerciales y optimizando la asignación de recursos.

RECOMENDACIONES

El código fuente utilizado para el desarrollo de este proyecto, incluyendo las etapas de preprocesamiento, análisis exploratorio, construcción de modelos de clasificación y forecasting, se encuentra disponible en el siguiente repositorio:

<https://github.com/GeorgeMedin/proyecto-mineria-datos-modelado-predictivo-forecasting/tree/main>

o mediante Google Colab con el siguiente link:

<https://colab.research.google.com/drive/1VFj2FilCWUtxYKnDauH1ALuAm-SonoGv?usp=sharing>

La disponibilidad del código permite replicar los resultados obtenidos, verificar la metodología aplicada y facilitar futuras mejoras o extensiones del proyecto.

TRABAJOS CITADOS

- Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. *Journal of Database Marketing & Customer Strategy Management*, 19(3), 197–208. <https://doi.org/10.1057/dbm.2012.17>
- Fawcett, T. (2006). An introduction to ROC analysis. **Pattern Recognition Letters**, 27(8), 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>
- Box, G. E., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5.^a ed.). John Wiley & Sons.
- Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366a), 427–431. <https://doi.org/10.1080/01621459.1979.10482531>